

memory实现方案汇报

记忆系统设计汇报

一、用户需求与痛点

用户的直接体感优先

	用户需求
1	下次少解释、别犯旧错、能接着干，不会”重启“
2	记忆必须放在合适位置
3	记住长期稳定、跨任务复用的信息
4	记住当前和过去的任务状态与事实
5	能说明依据，不污染上下文
6	需要流式进行记忆的探测
7	新session的warmup
8	精准地识别偏好
9	跨session任务的冷启动

基于以上问题，我们梳理了当前记忆系统的实现范式，并决定在此基础上做出差异化设计。


二、整体思路：双重表征+ 符号优先

2.1 主流记忆系统范式总结

双重表征记忆架构

	LLM	LOM
记	摘要/分块	关键词抽取
忆	向量检索	匹配

这套混合架构契合人脑双通路记忆机制：向量检索实现语义模糊联想，符号匹配完成精准事实调取；摘要则负责原始信息凝练。



Mem0、Zen、Graphiti、Hindsight、Mempalace 等主流开源记忆框架均符合该范式，但现有落地实践几乎全部以 LLM 向量支路作为系统主导。

这种架构下普遍存在的问题：

事实精确性差（痛点 2, 8），过量召回（痛点 2, 5, 6），事实关联能力差（痛点 1, 3, 4, 5, 7, 9），时序能力与追溯能力差（痛点 3, 4, 5）等

我们认为这些问题很多是**向量模糊匹配**的局限性以及**没有显式地动态地进行本体建模**导致的
希望通过以符号为主，向量语义补足的架构方式来解决这些问题

	LLM	LOM
记	摘要/分块	KEOL
忆	向量检索	模式匹配

2.1符号记忆系统设计

针对提到的用户痛点与LLM能力主导的记忆系统的局限，我们进行了以下的设计

1.以一轮对话为基础操作单元。

对一轮对话抽KE，保证完整地保留原始信息。

2.采用KEOL进行本体构建。

（针对 事实精确性差）

确保 KE 的表达能力。在KEOL不足的情况下，考虑先用ES搜索引擎的词表作为本体辅助。

-KEOL建的本体 与已有的本体怎么融合

3.建立多层级的索引系统，多层级地进行摘要并抽KE，找到跨session 跨对话的信息。

(针对 过量召回、事实关联能力差)

针对事实关联能力差的问题，向上抽象 Task 等跨会话的概念，实现跨对话、跨 session 信息关联检索。

4.建立KE适配的匹配系统，用于符号的召回模块。

(针对 过量召回)

针对KE做模式匹配


5.建立snapshot机制，确保记忆的可追溯性。

(针对 时序能力与追溯)

利用git等工具做到便捷地追溯，体现在产品上为给用户提供新对话的背景选项，不需要重复输入。

6.引入embedding进行补足

(防止符号系统语义泛化性不足)



三、待决策分歧点

以下是当前方案中需要进一步讨论确认的关键决策：

序号	决策点	方案一	方案二
1	技术路线重心	以符号KEOL为主，LLM补足	以LLM为主，符号补充
2	KE构建粒度	以一轮对话为单位建KE	以单句或完整session为
3	多层级索引范围	跨对话、跨session多层建KE	仅在单会话内建KE
4	本体构建方式	KEOL + ES词表手动建本体并行	完全依赖KEOL自动抽取

总结：

- 1.目前的记忆系统治理范围还是agent自身产生的记忆
外部的记忆库考虑暂时以搜索引擎的方式接入
- 2.记忆是多层级的，除了以一轮对话为单位抽KE，需要抽出跨对话跨session的
task 等概念
- 3.采用KEOL自动构建 和 ES词表+手动构建的方式建本体
但是需要考虑两种本体融合的方式